

ACADEMIA DE STUDII ECONOMICE BUCUREȘTI
FACULTATEA DE CIBERNETICĂ STATISTICĂ ȘI INFORMATICĂ
ECONOMICĂ



PROIECT

Software pentru Statistică și Data Science

Analize și predicții ale consumului de gaze naturale în România
utilizând Modele Autoregresive de Medie Mobilă



Coordonator științific:

Prof. Univ. Dr. FURTUNĂ Titus Felix

Realizat de:

Nume prenume	Drăghicescu Alexandra-Elena
Grupa	1134

București 2024

CUPRINS

INTRODUCERE.....	3
1.STADIUL CUNOAȘTERII.....	4
2.METODE UTILIZATE ÎN ANALIZA TEMATICII.....	5
Modele Autoregresive de Medie Mobilă	5
3.METODOLOGIA CERCETĂRII.....	6
3.1. Descrierea datelor	6
3.2. Compunerea modelului de analiză	7
4.REZULTATE EMPIRICE.....	8
Analiza cererii prin modelele statistice autoregresive de medie mobilă	8
5.CONCLUZII	14
BIBLIOGRAFIE.....	15

INTRODUCERE

Piața de gaze naturale, compusă din cerere și ofertă, este una dinamică și are importanță majoră în domeniul economico-financiar, mai ales în contextul spațio-temporal actual.

Odată cu izbucnirea conflictului dintre Rusia și Ucraina, de la începutul anului 2022, piața de gaze naturale mondială, dar mai ales cea europeană a fost cu adevărat impactată. Din cauza interdicțiilor impuse de țările membre U.E. pentru a limita interacțiunile de orice fel cu spațiul rusesc, s-a pus problema alimentării statelor membre cu resursa de gaze naturale, Rusia fiind principalul furnizor de resursă.

Ținând cont de acest context, este cu adevărat necesar realizarea de analize și predicții pentru cererea și ofertă de gaze naturale, astfel încât organele de conducere din diferitele țări membre U.E. să poată lua decizii și să asigure un necesar de resursă suficient pentru consumul de la nivelul populației.

Piața din România este direct afectată la rândul ei de aceste decizii de limitare a interacțiunilor cu Rusia, luate la nivelul blocului comunitar U.E. . Chiar dacă România posedă depozite de gaze naturale pe teritoriul național, acestea nu sunt în totalitate suficiente pentru a acoperi cererea de resursă din rândul populației. În consecință, pentru a satisface pe cât posibil în totalitate această nevoie de resursă de gaz, România apelează la import. Chiar dacă, în mod oficial, Rusia nu se numără printre partenerii de pe piața importului, originea gazului care trece prin Ungaria sau Ucraina este, în cea mai mare parte, de rusească.

La o primă vedere a datelor numerice este greu de făcut o estimare a cererii și ofertei de gaze naturale pe baza lor. Astfel, diferitele tehnici și algoritmi specializați de Machine Learning par a fi soluția ideală pentru a previziona cererea și oferta de gaze naturale într-un context spațio-temporal (Meira *et al.*, 2022).

Într-o abordare mai generală, în ceea ce privește problematica analizei și a predicției în diferitele domenii de interes economic, modelele de Machine Learning sunt din ce în ce mai des folosite.

Considerând a fi un subiect de actualitate, în acest studiu de caz am ales să evidențiez utilitatea în analiză și predicție a tehnicilor de calcul specifice domeniului de Inteligență Artificială și Machine Learning.

Rezultatele empirice ale calculelor arată că fenomenul cererii de gaze naturale, reprezentat de consumul efectiv, este mai bine explicat de un model statistic autoregresiv.

1.STADIUL CUNOAȘTERII

Cererea de gaze naturale, reprezentând consumul efectiv, are la bază în primul rând componenta climatică. Elementul climatic joacă rol de componentă sezonieră în descrierea consumului de gaze.

Fenomenele și temperaturile extreme sunt principalul motiv al creșterii cererii pentru această resursă, așa cum este demonstrat și în diferitele studii de specialitate despre predicția volatilității resursei de gaz natural (Liang *et al.*, 2022).

În perioada sezonului rece(toamnă-iarnă),de regulă,între lunile Septembrie-Aprilie,odată cu temperaturile scăzute, cererea de gaze naturale,atât la nivelul consumatorului casnic,cât și la nivelul celui industrial,crește automat din nevoia de a produce energie pentru încălzire.În perioada sezonului cald,cu precădere între lunile mai-august,are loc fenomenul opus celui prezentat anterior,și astfel,odată cu temperaturile ridicate, nevoia,respectiv cererea de gaze naturale scade.

Pentru cei mai mulți dintre indivizi,pe lângă factorul climatic,mai apare și problema prețului resursei.Un alt studiu reprezentativ (Uribe *et al.*, 2022) afirmă că aceste fenomene meteo extreme au un impact și asupra dinamicii prețului de tranzacție al resursei.Astfel,în mod așteptat,odată cu creșterea cererii,va exista creștere și în prețul pe unitate al resursei. Pentru consumator,prețul final este un factor decizional în ceea ce privește cererea din respectiva resursă.

Mai mult,cererea de resursă este influențată în mod direct și de diferitele evenimente geo-politice sau economice din ultima perioadă. Pentru actualul studiu de caz,cel mai reprezentativ exemplu este dat de actuala criză izbucnită în urma războiului de la graniță.

În ultimii doi ani,odată cu apariția conflictului dintre Rusia și Ucraina,piața energiei la nivel mondial,dar în special cea la nivel european,a fost complet dată peste cap.Ca o consecință a acestor sancțiuni impuse la nivelul blocului european, prețul gazelor naturale a urmat un trend continuu ascendent în ultima perioadă.

Astfel,în cazul consumatorilor de rând,cei casnici, al căror venit a rămas constant la nivelul perioadei din *pre-război* ,odată cu creșterea rapidă a prețului de gaze naturale raportat la unitatea consumată, cei mai mulți dintre ei au fost nevoiți să reducă consumul de energie pe timpul sezonului rece trecut.

În cazul consumatorilor industriali(fabricile de producție),odată cu creșterea prețului materiilor prime(a gazelor), de cele mai multe ori,costurile de producție depășeau veniturile încasate,ajungând astfel într-o situație de pierdere a exercițiului economico-financiar.

2.METODE UTILIZATE ÎN ANALIZA TEMATICII

Modele Autoregresive de Medie Mobilă

ARIMA (Autoregressive Integrated Moving Average) și SARIMA (Seasonal ARIMA) sunt modele statistice utilizate pentru analiza și prognozarea seriilor de timp. Acestea sunt utile în identificarea și modelarea tendințelor, sezoanelor și componentelor de eroare.

Modelul ARIMA este alcătuit din trei componente principale: AR (autoregresie), I (integrare) și MA (medie mobilă). Aceste componente descriu relația între valorile anterioare ale seriei de timp și valorile curente sau viitoare.

Componenta AR (autoregresie) indică faptul că valoarea curentă a seriei de timp depinde de valorile anterioare ale aceleiași serii. Modelul AR presupune că valorile trecute ale seriei pot influența valorile viitoare.

Componenta I (integrare) este utilizată pentru a face seria de timp staționară. Staționaritatea implică faptul că proprietățile seriei de timp (media și varianța) sunt constante în timp. Integrarea implică diferențierea seriei de timp pentru a elimina tendințele non-staționare.

Componenta MA (medie mobilă) indică faptul că valorile curente ale seriei de timp depind de erorile de previziune anterioare. Modelul MA presupune că valorile anterioare ale erorilor de previziune pot influența valorile viitoare ale seriei de timp.

Modelul ARIMA este notat $ARIMA(p, d, q)$.

Modelul SARIMA extinde modelul ARIMA pentru a include și componente sezoniere, componente utile în cazul seriilor de timp care prezintă sezoane în anumite intervale de timp.

Acesta adaugă trei parametri la modelul ARIMA, notat $SARIMA(p, d, q)(P, D, Q, s)$, unde:

- p = ordinul componentei AR, numărul de termeni autoregresivi din model;
- d = ordinul componentei I, numărul de diferențe pentru a obține o serie staționară;
- q = ordinul componentei MA, numărul de termeni de medie mobilă utilizați în model;
- P = ordinul componentei sezoniere AR (autoregresie);
- D = ordinul componentei sezoniere I (integrare);
- Q = ordinul componentei sezoniere MA (medie mobilă);
- s = lungimea sezonului;

În diferitele studii de specialitate deja efectuate, modele ARIMA și SARIMA au fost folosite pentru a prognoza diferite fenomene cu importanță economico-financiară.

3.METODOLOGIA CERCETĂRII

3.1. Descrierea datelor

Această lucrare are ca scop analiza și predicția cererii și ofertei de gaze naturale din România folosind Modele Autoregresive de Medie Mobilă.

Pentru acest studiu,am considerat ca sursă de date platforma oficială EUROSTAT prin diferitele seturi de date customizabile. Ca perioadă de referință,am ales date cu frecvență lunară sau anuală,începând cu ianuarie 2014 și până la noiembrie 2023,acolo unde a fost posibil.În caz contrar,seturile de date au fost preluate până la ultima înregistrare din 2022.Am ținut cont ca în acest interval de timp să fie capturate mai multe evenimente economice majore cu puternic impact asupra pieței de gaze naturale.

Pentru componenta cererii am considerat relevante a fi datele despre consumul efectiv înregistrat la nivelul țării.Am preluat date cu frecvență lunară din setul de date **nrg_cb_gasm** de la secțiunea *Inland consumption*. Pe baza acestui set de date am creat o serie de timp de 119 înregistrări care capturează consumul de gaze naturale,măsurat în milioane de metri cubi, la nivelul României pentru perioada ianuarie 2014 – noiembrie 2023(EUROSTAT, 2023d).

consum	
perioada	
2014-01-01	1392
2014-02-01	1301
2014-03-01	1064
2014-04-01	954
2014-05-01	777
...	...
2023-07-01	423
2023-08-01	407
2023-09-01	434
2023-10-01	629
2023-11-01	1089

119 rows × 1 columns

Figura nr.1.Consumul de gaze înregistrat în România între ianuarie 2014 și noiembrie 2023

Sursa: Arhiva personală prelucrare în limbaj Python

La nivel vizual, se poate observa distribuția seriei de timp a consumului de gaze naturale pentru perioada de referință menționată anterior în *Figura nr.3.2.* .




Figura nr.2. Grafic al seriei de consum înregistrat între ianuarie 2014 și noiembrie 2023

Sursa: Arhiva personală prelucrare în limbaj Python

3.2. Compunerea modelului de analiză

În funcție de componentele specifice seriei de timp a consumului de gaze, diferite modele sunt propuse spre analiză și, ulterior, spre comparații.

Ca și modele propuse, seria de timp a consumului va trece prin analiza proceselor de tip ARIMA/SARIMA.

Seria de timp a cererii de gaze naturale, mai exact a variabilei de consum, are, în mod așteptat, o componentă puternică de sezonabilitate. Pentru perioada sezonului rece, între lunile septembrie și martie, cererea din resursă crește, odată cu nevoia de consum de energie, iar pe timpul perioadei sezonului cald, această cerere de resursă scade.

Astfel, pentru metoda statistică se recomandă testul ADF pentru verificarea staționariatății seriei. Ulterior, se propune descompunerea sezonieră și diferențierea de ordin 1. Mai specific, cum seria prezintă în mod evident sezonabilitate, este recomandat a se analiza un model SARIMA pe seria diferențiată, pentru a putea obține rezultate relevante în urma predicției. În cazul ofertei, unde sezonabilitatea nu este la fel de pregnantă, se recomandă analiza unui model ARIMA pe seria inițială.

4.REZULTATE EMPIRICE

Analiza cererii prin modelele statistice autoregresive de medie mobilă

Pentru analiza pe baza modelelor autoregresive și de medie mobilă, mai multe etape vor fi urmate în mod sistematic în cadrul procesului de prognoză.

1. Vizualizare grafic componente specifice seriei de timp prin comanda `seasonal_decompose`;




Figura nr.3. Grafice descompunere sezonieră a seriei de consum

Sursa: Arhiva personală prelucrare în limbaj Python

Din graficele de descompunere sezonieră din *Figura nr.4.1.*, la o primă vedere, se poate observa existența componentei sezoniere în seria de timp a consumului, sugerată atât de graficul seriei originale, cât și de cel specific componentei sezoniere.

Trendul urmărește la rândul lui componenta sezonieră, astfel că se poate constata că în lunile sezonului rece acesta crește ușor, iar în lunile sezonului cald are tendința de a scădea.

Distribuția neuniformă a reziduurilor sugerează nestăționaritatea seriei.

Mai departe, se va efectua testul ADF pentru a verifica stăționaritatea seriei.

2. Test ADF Staționaritate serie ;




Figura nr.4. Grafic testare staționaritate a seriei de consum

Sursa: Arhiva personală prelucrare în limbaj Python

Rezultatele obținute în urma testului, $p\text{-value}=0.93$, confirmă că seria nu este staționară.

Pentru a putea realiza analiza seriei de timp, următoarea etapă este aceea de diferențiere de ordinul 1, prin comanda `df.diff()` din limbajul Python. Pasul imediat următor este de a testa din nou staționaritatea pentru noua serie obținută în urma diferențierii.

3. Test ADF staționaritate serie diferențiată




Figura nr.5. Grafic testare staționaritate a seriei de consum diferențiate

Sursa: Arhiva personală prelucrare în limbaj Python

Cum rezultatele noului test ADF atestă staționaritatea, $p\text{-value}=0.007$, se poate trece la pasul următor, cel de divizare al setului de date.

4.Împărțirea setului de date pe set de antrenare și testare;

Vom considera 87% din valori ca alcătuind setul de antrenare,specific se va obține o serie de 103 valori corespunzătoare perioadei de la ianuarie 2014 și până la iulie 2022, inclusiv. Restul de 13%(16 valori corespunzătoare pentru restul perioadei anului 2022 și cele 11 luni ale anului 2023) vor alcătui setul de testare,pentru care se vor face prognozele.

Aceste seturi de date vor fi salvate individual sub forma de csv pentru a se putea lucra și individual.

consum		consum	
perioada		perioada	
2014-01-01	1392	2022-08-01	435
2014-02-01	1301	2022-09-01	493
2014-03-01	1064	2022-10-01	637
2014-04-01	954	2022-11-01	965
2014-05-01	777	2022-12-01	1309
...	...	2023-01-01	1295
2022-03-01	1247	2023-02-01	1300
2022-04-01	729	2023-03-01	1004
2022-05-01	576	2023-04-01	754
2022-06-01	490	2023-05-01	473
2022-07-01	455	2023-06-01	357
103 rows × 1 columns		2023-07-01	423
		2023-08-01	407
		2023-09-01	434
		2023-10-01	629
		2023-11-01	1089

Figura nr.6.Seturi de date de testare și antrenare

Sursa: Arhiva personală prelucrare în limbaj Python

Pe baza acestor valori, la pasul următor,se va realiza graficul ACF.

5.Grafic ACF;




Figura nr.7.Grafic ACF al seriei de consum diferențiate

Sursa: Arhiva personală prelucrare în limbaj Python

Se poate observa, în *Figura nr.4.4.*, prezența elementului de sezonaliitate și periodicitatea de 12 luni a seriei de timp. Ulterior, se va alege un model optim pentru realizarea predicției.

6. Căutare model optim SARIMA;

Prin comanda specifică limbajului Python, *pm.auto_arima*, se va găsi automat pe baza datelor din setul de antrenare modelul optim SARIMA.

```
Best model: ARIMA(0,0,1)(0,1,1)[12]
Total fit time: 20.169 seconds

=====
SARIMAX Results
=====
Dep. Variable: y No. Observations: 103
Model: SARIMAX(0, 0, 1)x(0, 1, 1, 12) Log Likelihood: -580.995
Date: Wed, 27 Dec 2023 AIC: 1167.991
Time: 10:47:32 BIC: 1175.523
Sample: 01-01-2014 HQIC: 1171.030
- 07-01-2022

Covariance Type: opg
=====
coef      std err      z      P>|z|      [0.025      0.975]
-----
ma.L1      0.4100      0.085      4.829      0.000      0.244      0.576
ma.S.L12    -0.6680      0.136     -4.909      0.000     -0.935     -0.401
sigma2     1.894e+04    1840.694    10.289      0.000    1.53e+04    2.25e+04
=====
Ljung-Box (L1) (Q):      0.03  Jarque-Bera (JB):      119.77
Prob(Q):      0.86  Prob(JB):      0.00
Heteroskedasticity (H):      0.62  Skew:      1.45
Prob(H) (two-sided):      0.20  Kurtosis:      7.82
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

Figura nr.8. Output pentru calcul model ARIMA

Sursa: Arhiva personală prelucrare în limbaj Python

În urma procesului, modelul optim identificat este de tipul SARIMA(0, 0, 1)x(0, 1, 1, 12). Pe baza lui se vor calcula ipotezele și graficele pentru distribuția reziduurilor.

7. Analiza ipoteze pe reziduuri pentru modelul ales SARIMAX(2, 1, 0)x(2, 1, 0, 12);

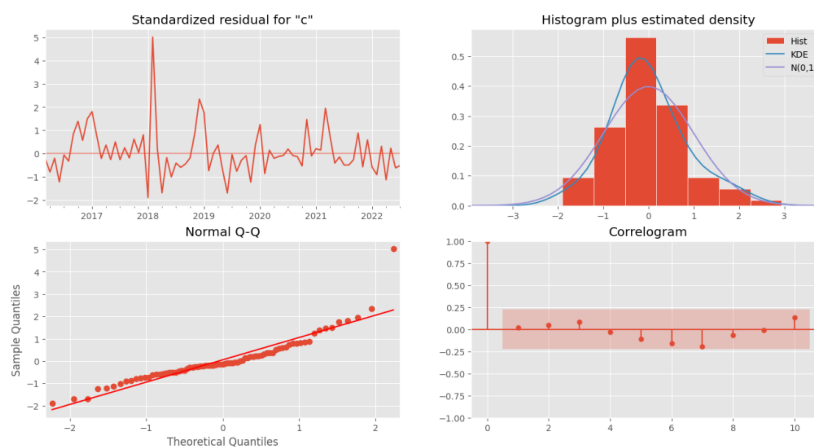


Figura nr.9. Grafice pentru ipotezele pe reziduuri pentru modelul ales SARIMA

Sursa: Arhiva personală prelucrare în limbaj Python

Conform rezultatelor obținute prezentate în *Figura nr.4.6.*,reziduurile urmează o distribuție heteroscedastică,iar valorile previzionate sunt corelate cu valorile reale.Forma și limita histogramei sugerează o distribuție normală a valorilor previzionate. Se poate concluziona că modelul ales este unul bun și se poate realiza graficul de prognoză.

8.Grafic prognoza consum de gaze naturale pe baza datelor din setul de antrenare al seriei diferențiate ;




Figura nr.10.Grafic prognoza de consum de gaze naturale prin metoda SARIMA

Sursa: Arhiva personală prelucrare în limbaj Python

9.Previzionare consum de gaze pentru perioadele viitoare alese ;

Ulterior,pe baza rezultatelor previzionate,se va realiza și prognoza pentru perioadele viitoare.Am ales ca perioada de interes de previziune următorii 2 ani calendaristici,respectiv 2024 si 2025.Ținând cont de trendul urmat de-a lungul timpului,sezonalitatea și datele istorice joacă un rol important în estimarea consumului din viitor.

Ținând cont de datele din setul de antrenare,valorii specifice setului de testare vor fi previzionate și ulterior și pentru perioada de prognoză aleasă,respectiv pentru următoarele 24 luni.

Aceasta estimare se poate observa atât vizual,la nivelul graficului sub forma de evoluție a serie de timp aleasă,ca în figura de mai jos:




Figura nr.11. Grafic previziune de consum de gaze naturale pentru 2024-2025

Sursa: Arhiva personală prelucrare în limbaj Python

Dar și la nivel numeric/valoric, sub formă unei serii de timp tabelară (data frame), după cum urmează:

Consum prognozat prin SARIMA	
2023-12-01	1512.045980
2024-01-01	1622.111096
2024-02-01	1385.189863
2024-03-01	1260.964695
2024-04-01	829.123988
2024-05-01	609.280508
2024-06-01	541.946664
2024-07-01	538.874724
2024-08-01	573.646399
2024-09-01	631.727664
2024-10-01	880.062216
2024-11-01	1223.664116
2024-12-01	1512.045980
2025-01-01	1622.111096
2025-02-01	1385.189863
2025-03-01	1260.964695
2025-04-01	829.123988
2025-05-01	609.280508
2025-06-01	541.946664
2025-07-01	538.874724
2025-08-01	573.646399
2025-09-01	631.727664
2025-10-01	880.062216
2025-11-01	1223.664116
2025-12-01	1512.045980

Figura nr.12. Tabel previziune de consum de gaze naturale pentru 2024-2025

Sursa: Arhiva personală prelucrare în limbaj Python

5.CONCLUZII

În urma tehnici de analiză și modelare utilizată în acest studiu se poate concluziona utilitatea tehnicilor de Inteligență Artificială și Machine Learning în procesul de predicție a diferitelor fenomene economico-financiare.

În ceea ce privește cererea de gaze naturale, prin prisma componentei temporale, aceasta este mai bine previzionată printr-un proces statistic autoregresiv de medie mobilă de tipul SARIMAX(2, 1, 0)x(2, 1, 0, 12). Rezultatul este unul așteptat, deoarece, în această ipoteză componenta sezonieră a seriei consumului este mult mai bine explicată prin acest proces statistic. O explicație validă este aceea că, în cazul modelelor SARIMA, pentru procesul de predicție va fi luată în considerare componenta sezonieră a seriei, dar și valorile numerice ale perioadelor trecute din setul de antrenare pe baza căruia se calculează valorile previzionate. În mod evident, cum consumul, respectiv cererea este mai mare în perioada sezonului rece, se așteaptă ca și pentru următorul sezon rece să se respecte același trend.

Cu alte cuvinte, cererea de gaze din România, reprezentată prin variabila de consum, oscilează în jurul valorii de 1300 milioane metri cubi pentru perioada sezonului rece, considerat a fi între lunile septembrie și martie, iar în cazul sezonului cald, cererea de gaze naturale se învârtă în jurul valorii de 500 milioane metri cubi.

În contextul actual, atât determinat de conflictul de la graniță, dar și de fenomenul tot mai actual al Încălzirii Globale, astfel de analize și predicții sunt foarte necesare.

Diferitele organe de control de la nivel local sau mondial, pe baza acestor tipuri de analize, pot lua anumite decizii care să aibă impact economic asupra pieței de gaze naturale în general.

Astfel, de exemplu, pentru a limita interacțiunea și importul de resursă de gaz rusesc, se pot propune noi parteneri strategici sau surse alternative de extracție locale. Mai mult, în aceeași idee, pentru a reduce extracția de resursă și a reduce fenomene climatice extreme determinate de Încălzirea Globală, alte tipuri de resurse mai prietenoase cu mediul pot fi o alternativă la extracția și utilizarea gazului natural ca sursă primară de energie.

Aceste analize și predicții au un caracter aplicativ pentru tehnicile de modelare propuse, fiind realizate pentru un orizont de timp pe termen scurt. Pot fi considerate un punct de plecare în ceea ce privește luarea de decizii pe termen lung la nivel mondial pentru evoluția pieței de gaze naturale, însă nu trebuie considerate ca având un caracter general valabil.

BIBLIOGRAFIE

- [1] ANRE. (2022) *Rapoarte Lunare de Monitorizare Pentru Piața Internă de Gaze Naturale 2022*. ANRE. Available at: <https://arhiva.anre.ro/ro/gaze-naturale/rapoarte/rapoarte-piata-gaze-naturale/rapoarte-lunare-de-monitorizare-pentru-piata-interna-de-gaze-naturale-2022>
- [2] Beyca, O.F. *et al.* (2019) 'Using Machine Learning Tools for Forecasting Natural Gas Consumption in the Province of Istanbul'. *Energy Economics*, 80. DOI: 10.1016/j.eneco.2019.03.006.
- [3] European Council. (2023) *Infographic - EU Sanctions in Response to Russia's Invasion of Ukraine*. Available at: <https://www.consilium.europa.eu/en/infographics/eu-sanctions-russia-ukraine-invasion/>
- [4] EUROSTAT. (2023d) *Supply, Transformation and Consumption of Gas*. Available at: https://ec.europa.eu/eurostat/web/products-datasets/-/nrg_cb_gas
- [5] He, K. *et al.* (2021) 'Using SARIMA–CNN–LSTM Approach to Forecast Daily Tourism Demand'. *Journal of Hospitality and Tourism Management*, 49. DOI: 10.1016/j.jhtm.2021.08.022.
- [6] International Gas Union. (2018) *2018 Global Gas Report. Snam, International Gas Union and The Boston Consulting Group*. Available at: <https://www.igu.org/news/2018-global-gas-report/>
- [7] Liang, C. *et al.* (2022) 'Natural Gas Volatility Prediction: Fresh Evidence from Extreme Weather and Extended GARCH-MIDAS-ES Model'. *Energy Economics*, 116. DOI: 10.1016/j.eneco.2022.106437.
- [8] Meira, E., Cyrino Oliveira, F.L. and de Menezes, L.M. (2022) 'Forecasting Natural Gas Consumption Using Bagging and Modified Regularization Techniques'. *Energy Economics*, 106. DOI: 10.1016/j.eneco.2021.105760.
- [9] Olmez Turan, M. and Flamand, T. (2023) 'Optimizing Investment and Transportation Decisions for the European Natural Gas Supply Chain'. *Applied Energy*, 337. DOI: 10.1016/j.apenergy.2023.120859.
- [10] Öztunç Kaymak, Ö. and Kaymak, Y. (2022) 'Prediction of Crude Oil Prices in COVID-19 Outbreak Using Real Data'. *Chaos, Solitons and Fractals*, 158. DOI: 10.1016/j.chaos.2022.111990.
- [11] Petkovic, M., Koch, T. and Zittel, J. (2022) 'Deep Learning for Spatio-Temporal Supply and Demand Forecasting in Natural Gas Transmission Networks'. *Energy Science and Engineering*, 10(6). DOI: 10.1002/ese3.932.
- [12] Rick, R. and Berton, L. (2022) 'Energy Forecasting Model Based on CNN-LSTM-AE for Many Time Series with Unequal Lengths'. *Engineering Applications of Artificial Intelligence*, 113. DOI: 10.1016/j.engappai.2022.104998.
- [13] Sen, D. *et al.* (2023) 'Forecasting Long-Term World Annual Natural Gas Production by Machine Learning'. *Resources Policy*, 80. DOI: 10.1016/j.resourpol.2022.103224.
- [14] Song, J. *et al.* (2022) 'Estimate the Daily Consumption of Natural Gas in District Heating System Based on a Hybrid Seasonal Decomposition and Temporal Convolutional Network Model'. *Applied Energy*, 309. DOI: 10.1016/j.apenergy.2021.118444.
- [15] Stelian Stancu. (2020) *Machine Learning, Deep Learning, Deep Neural Network in Mediul R. Teorie Si Aplicatii*. colecția cibernetică. București: Editura ASE